

Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет компьютерных систем и сетей
Кафедра программного обеспечения информационных технологий

ОТЧЕТ
по лабораторной работе № 2
по дисциплине «Методы машинного обучения»
на тему
«Знакомство с инструментами сбора и подготовки данных»

Выполнил: студент гр. 351002
Проверил:

Лащенко Е.Н.
Лебедев А.В.

Минск 2026

1 ЦЕЛЬ РАБОТЫ

Цель работы – освоить сбор и подготовку табличных данных на примере набора «Student Performance Factors».

В ходе работы решаются следующие задачи:

- импортировать данные и описать состав признаков;
- найти пропуски и аномальные значения, устранить их и проверить результат;
- сформировать новые признаки и закодировать категориальные переменные;
- выполнить стандартизацию и нормализацию числовой матрицы признаков.

Подготовка выполнена на языке Python с библиотеками pandas, NumPy, matplotlib, seaborn и scikit-learn.

2 ИМПОРТ ДАННЫХ

2.1 Загрузка набора

Исходный файл StudentPerformanceFactors.csv считывается в таблицу pandas вызовом read_csv. После загрузки таблица содержит 6607 наблюдений и 20 признаков. Семь столбцов имеют тип int64, тринадцать – тип str. Объём таблицы в памяти составляет около 1 МБ. Каждая строка описывает одного учащегося, целевой величиной служит балл экзамена Exam_Score.

2.2 Состав признаков

Категориальные признаки принимают два или три уровня. Состав набора приведён в таблице 2.1.

Таблица 2.1 – Признаки исходного набора

Признак	Тип	Содержание
Hours_Studied	числовой	Число часов учёбы
Attendance	числовой	Посещаемость, %
Parental_Involvement	категориальный	Участие родителей
Access_to_Resources	категориальный	Доступ к учебным ресурсам
Extracurricular_Activities	категориальный	Внеучебная деятельность
Sleep_Hours	числовой	Продолжительность сна, ч
Previous_Scores	числовой	Предыдущие оценки
Motivation_Level	категориальный	Уровень мотивации
Internet_Access	категориальный	Доступ в интернет
Tutoring_Sessions	числовой	Число занятий с репетитором
Family_Income	категориальный	Доход семьи
Teacher_Quality	категориальный	Качество преподавания
School_Type	категориальный	Тип школы
Peer_Influence	категориальный	Влияние сверстников
Physical_Activity	числовой	Физическая активность
Learning_Disabilities	категориальный	Трудности в обучении
Parental_Education_Level	категориальный	Образование родителей
Distance_from_Home	категориальный	Удалённость от дома
Gender	категориальный	Пол
Exam_Score	числовой	Балл экзамена

Упорядоченные уровни Low, Medium и High встречаются у участия родителей, доступа к ресурсам, мотивации, дохода семьи и качества преподавания. Образование родителей задано уровнями High School, College и Postgraduate, удалённость – уровнями Near, Moderate и Far. Тип школы принимает значения Public и Private, влияние сверстников – Negative, Neutral и

Positive. Остальные категориальные признаки двоичные: Yes/No либо Male/Female.

2.3 Числовые характеристики

Среднее, стандартное отклонение (столбец «Отклонение»), минимум и максимум числовых признаков приведены в таблице 2.2. Медиана балла экзамена равна 67 при межквартильном размахе от 65 до 69, то есть основная масса оценок сосредоточена в узком интервале. Максимум Exam_Score равен 101, что выходит за допустимую шкалу балла.

Таблица 2.2 – Описательные статистики числовых признаков

Признак	Среднее	Отклонение	Минимум	Максимум
Hours_Studied	19,98	5,99	1	44
Attendance	79,98	11,55	60	100
Sleep_Hours	7,03	1,47	4	10
Previous_Scores	75,07	14,40	50	100
Tutoring_Sessions	1,49	1,23	0	8
Physical_Activity	2,97	1,03	0	6
Exam_Score	67,24	3,89	55	101

Наиболее частые категории, которые далее используются при заполнении пропусков: качество преподавания Medium (3925 наблюдений из 6529 заполненных), образование родителей High School (3223 из 6517), удалённость Near (3884 из 6540).

3 ПРОПУСКИ И АНОМАЛЬНЫЕ ЗНАЧЕНИЯ

3.1 Анализ пропусков

Пропуски есть только в трёх категориальных столбцах. Подсчёт выполняется следующим фрагментом.

```
missing = df.isna().sum()
missing_pct = (missing / len(df) * 100).round(2)
missing_table = pd.DataFrame({
    "Пропуски": missing,
    "Доля, %": missing_pct,
})
missing_table = missing_table[missing_table["Пропуски"] > 0]
missing_table = missing_table.sort_values("Пропуски", ascending=False)
```

Результат сведён в таблицу 3.1. Всего пропущено 235 значений, они затрагивают 229 строк, то есть 3,47 % выборки. Доля пропусков в каждом столбце не превышает 1,36 %, поэтому удаление неполных строк нецелесообразно: теряется меньше информации, если заполнить пропуск типичным уровнем категории.

Таблица 3.1 – Пропущенные значения

Признак	Число пропусков	Доля, %
Parental_Education_Level	90	1,36
Teacher_Quality	78	1,18
Distance_from_Home	67	1,01

Расположение пропусков по строкам показано на рисунке 3.1. Отметки разрежены и не образуют сплошных блоков, совместное отсутствие сразу нескольких полей встречается редко: 235 пропусков приходится на 229 строк.




Рисунок 3.1 – Тепловая карта пропусков в исходной таблице

3.2 Распределения и связь признаков

К числовым признакам отнесены Hours_Studied, Attendance, Sleep_Hours, Previous_Scores, Tutoring_Sessions, Physical_Activity и Exam_Score. Остальные тринадцать признаков категориальные.

Гистограммы с оценкой плотности приведены на рисунке 3.2. Балл экзамена и посещаемость близки к симметричным распределениям. Число занятий с репетитором скошено вправо: мода равна 1, отдельные наблюдения доходят до 8. Часы учёбы имеют более тяжёлые хвосты, чем центральная часть выборки.




Рисунок 3.2 – Распределения числовых признаков

Диаграммы размаха на рисунке 3.3 подтверждают хвосты у `Hours_Studied`, `Tutoring_Sessions` и `Exam_Score`. У посещаемости, сна, предыдущих оценок и физической активности точки за «усами» не выделяются.




Рисунок 3.3 – Диаграммы размаха числовых признаков

Линейная связь числовых признаков показана на рисунке 3.4. Вне балла экзамена коэффициенты корреляции по модулю не превышают 0,03, то есть предикторы между собой практически не коррелированы.




Рисунок 3.4 – Корреляционная матрица числовых признаков

Связь с баллом экзамена приведена в таблице 3.2. Сильнее всего балл связан с посещаемостью (0,581) и числом часов учёбы (0,445). Предыдущие оценки и занятия с репетитором дают слабую положительную связь. Сон и физическая активность с баллом линейно почти не связаны.

Таблица 3.2 – Коэффициенты корреляции с баллом экзамена

Признак	Коэффициент корреляции
Attendance	0,581
Hours_Studied	0,445
Previous_Scores	0,175
Tutoring_Sessions	0,157
Physical_Activity	0,028
Sleep_Hours	−0,017

3.3 Поиск выбросов

Наблюдение считается выбросом, если оно лежит вне границ межквартильного размаха. Границы вычисляются по формулам:

$$IQR = Q_3 - Q_1, \quad (3.1)$$

$$L = Q_1 - 1,5 \cdot IQR, \quad (3.2)$$

$$U = Q_3 + 1,5 \cdot IQR, \quad (3.3)$$

где IQR – межквартильный размах;

Q_1 – первый квартиль;

Q_3 – третий квартиль;

L – нижняя граница;

U – верхняя граница.

Коэффициент 1,5 соответствует обычному правилу Тьюки. Расчёт границ для каждого числового столбца выполняется функцией, приведённой ниже.

```
def iqr_bounds(series, k=1.5):
    q1 = series.quantile(0.25)
    q3 = series.quantile(0.75)
    iqr = q3 - q1
    lower = q1 - k * iqr
    upper = q3 + k * iqr
    return lower, upper

for col in num_cols:
    lower, upper = iqr_bounds(df[col])
    mask = (df[col] < lower) | (df[col] > upper)
```

Полученные границы и число выбросов приведены в таблице 3.3.

Таблица 3.3 – Границы выбросов по правилу межквартильного размаха

Признак	Нижняя граница	Верхняя граница	Выбросы	Минимум	Максимум
Hours_Studied	4,00	36,00	43	1	44
Attendance	40,00	120,00	0	60	100
Sleep_Hours	3,00	11,00	0	4	10
Previous_Scores	25,50	125,50	0	50	100
Tutoring_Sessions	−0,50	3,50	430	0	8
Physical_Activity	−1,00	7,00	0	0	6
Exam_Score	59,00	75,00	104	55	101

Диапазоны Attendance, Sleep_Hours, Previous_Scores и Physical_Activity целиком лежат внутри границ, поэтому выбросов по этим признакам нет. Нижние границы Tutoring_Sessions и Physical_Activity отрицательны и в предметной области недостижимы: отсекается только правый хвост.

По часам учёбы за границы выходят 43 наблюдения: 21 значение меньше 4 и 22 значения больше 36. По занятиям с репетитором все 430 выбросов – это уровни от 4 до 8 занятий; значений ниже нуля в данных нет. По баллу экзамена 28 наблюдений ниже 59 и 76 наблюдений выше 75.

Отдельно проверяется предметное ограничение: балл экзамена не может быть больше 100. Такому условию не удовлетворяет одна строка (`Hours_Studied = 27`, `Attendance = 98`, `Previous_Scores = 93`, `Exam_Score = 101`). Она входит в 76 наблюдений с баллом выше 75.

Узкие границы `Exam_Score` объясняются малым разбросом балла: стандартное отклонение равно 3,89, квантили равны 65 и 69. Правило (3.2)–(3.3) относит к выбросам и редкие, но допустимые баллы от 55 до 58 и от 76 до 100. Это статистические хвосты, а не ошибки шкалы, кроме единственного значения 101.

3.4 Заполнение пропусков и удаление выбросов

Пропуски заполняются модой соответствующего столбца. Ошибочный балл ограничивается сверху значением 100. Затем удаляются строки, которые выходят за границы (3.2)–(3.3) по `Hours_Studied`, `Tutoring_Sessions` или `Exam_Score`. Признаки без выбросов и с естественным узким диапазоном фильтром не затрагиваются. Фрагмент очистки приведён ниже.

```
df_clean = df.copy()

cat_with_na = [
    "Teacher_Quality",
    "Parental_Education_Level",
    "Distance_from_Home",
]
for col in cat_with_na:
    mode_val = df_clean[col].mode(dropna=True)[0]
    df_clean[col] = df_clean[col].fillna(mode_val)

df_clean["Exam_Score"] = df_clean["Exam_Score"].clip(upper=100)

cols_for_iqr_removal = [
    "Hours_Studied",
    "Tutoring_Sessions",
    "Exam_Score",
]
mask_keep = pd.Series(True, index=df_clean.index)
for col in cols_for_iqr_removal:
    lower, upper = iqr_bounds(df_clean[col])
    col_mask = (df_clean[col] >= lower) & (df_clean[col] <= upper)
    mask_keep &= col_mask

df_clean = df_clean.loc[mask_keep].reset_index(drop=True)
```

Качество преподавания заполнено значением Medium (78 пропусков), образование родителей – значением High School (90 пропусков), удалённость – значением Near (67 пропусков). После заполнения пропущенных значений в таблице не остаётся.

Ограничение Exam_Score затрагивает одно значение: 101 заменяется на 100. Это наблюдение всё равно удаляется фильтром балла, поскольку 100 больше верхней границы 75.

Фильтр часов учёбы помечает 43 строки (границы от 4,00 до 36,00), фильтр занятий с репетитором – 430 строк (границы от –0,50 до 3,50), фильтр балла – 104 строки (границы от 59,00 до 75,00). Сумма этих чисел равна 577 и больше числа удалённых строк, так как часть наблюдений выходит за границы сразу по нескольким признакам. В выборке остаётся 6054 строки из 6607, удалено 553 строки (8,37 %).

Основной вклад в сокращение выборки даёт Tutoring_Sessions. Из-за правой асимметрии правило $1,5 \cdot \text{IQR}$ отсекает все наблюдения с четырьмя и более занятиями, хотя такие значения лежат на шкале признака. Итоговая выборка описывает типичную, а не полную учебную нагрузку с репетитором.

3.5 Проверка результата

Сумма пропусков после очистки равна нулю, значений Exam_Score больше 100 нет. Повторный расчёт по формулам (3.1)–(3.3) на очищенной выборке для Hours_Studied, Tutoring_Sessions и Exam_Score даёт ноль выбросов: новые границы не помечают оставшиеся точки.

Сопоставление тепловых карт до и после очистки показано на рисунке 3.5. Правая карта пустая.




Рисунок 3.5 – Пропуски до и после очистки

Диаграммы размаха тех же трёх признаков до и после удаления строк приведены на рисунке 3.6. Длинные хвосты исходных распределений на нижнем ряду отсутствуют.




Рисунок 3.6 – Диаграммы размаха до и после удаления выбросов

4 ГЕНЕРАЦИЯ ПРИЗНАКОВ И КОДИРОВАНИЕ

4.1 Новые признаки

По очищенной таблице из 6054 строк строятся четыре признака. Интенсивность учёбы учитывает и длительность занятий, и посещаемость:

$$S = h \cdot \left(\frac{a}{100} \right), \quad (4.1)$$

где h – число часов учёбы;

a – посещаемость, %.

Прирост балла относительно предыдущих оценок определяется по формуле:

$$G = e - p, \quad (4.2)$$

где e – балл текущего экзамена;

p – предыдущая оценка.

Близость продолжительности сна к середине интервала от 7 до 8 ч задаётся формулой:

$$B = 1 - \frac{|t-7,5|}{7,5}, \quad (4.3)$$

где t – продолжительность сна, ч.

Суммарная учебная нагрузка складывается из самостоятельной учёбы и занятий с репетитором:

$$W = h + r, \quad (4.4)$$

где r – число занятий с репетитором.

В таблице этим величинам соответствуют столбцы `Study_Intensity`, `Score_Gain`, `Sleep_Balance` и `Total_Learning_Load`. Вычисление приведено ниже.

```
df_feat = df_clean.copy()

df_feat["Study_Intensity"] = (
    df_feat["Hours_Studied"] * (df_feat["Attendance"] / 100)
)
df_feat["Score_Gain"] = df_feat["Exam_Score"] - df_feat["Previous_Scores"]
df_feat["Sleep_Balance"] = 1 - (df_feat["Sleep_Hours"] - 7.5).abs() / 7.5
```

```
df_feat["Total_Learning_Load"] = (
    df_feat["Hours_Studied"] + df_feat["Tutoring_Sessions"]
)
```

Среднее, стандартное отклонение (столбец «Отклонение»), минимум и максимум новых признаков приведены в таблице 4.1. Средний прирост балла отрицательный (−8,13): текущий экзамен в среднем ниже предыдущих оценок, размах прироста составляет от −39 до 22. Баланс сна сосредоточен у верхней части шкалы, поскольку типичная продолжительность сна равна 7–8 ч и даёт значение 0,93. Распределения показаны на рисунке 4.1.

Таблица 4.1 – Описательные статистики новых признаков

Признак	Среднее	Отклонение	Минимум	Максимум
Study_Intensity	15,99	5,13	2,56	34,56
Score_Gain	−8,13	14,07	−39,00	22,00
Sleep_Balance	0,83	0,12	0,53	0,93
Total_Learning_Load	21,31	5,85	4,00	38,00




Рисунок 4.1 – Распределения новых признаков

4.2 Бинаризация

Двоичные признаки с уровнями Yes и No переводятся в 1 и 0: внеучебная деятельность, доступ в интернет и трудности в обучении. Пол кодируется отдельно: Male получает 1, Female получает 0. Тип школы кодируется LabelBinarizer; для Public получается 1, для Private – 0. Фрагмент кодирования приведён ниже.

```
binary_yes_no = [
    "Extracurricular_Activities",
    "Internet_Access",
    "Learning_Disabilities",
]
for col in binary_yes_no:
    df_enc[col + "_bin"] = (df_enc[col] == "Yes").astype(int)

df_enc["Gender_bin"] = (df_enc["Gender"] == "Male").astype(int)
```

```

lb = LabelBinarizer()
df_enc["School_Type_bin"] = lb.fit_transform(df_enc["School_Type"]).ravel()

level_map = {"Low": 0, "Medium": 1, "High": 2}
ordinal_level_cols = [
    "Parental_Involvement",
    "Access_to_Resources",
    "Motivation_Level",
    "Family_Income",
    "Teacher_Quality",
]
for col in ordinal_level_cols:
    df_enc[col + "_ord"] = df_enc[col].map(level_map)

df_enc["Distance_from_Home_ord"] = df_enc["Distance_from_Home"].map(
    {"Near": 0, "Moderate": 1, "Far": 2}
)
df_enc["Parental_Education_Level_ord"] =
df_enc["Parental_Education_Level"].map(
    {"High School": 0, "College": 1, "Postgraduate": 2}
)

ohe = OneHotEncoder(sparse_output=False, drop="first")
ohe_cols = ["Peer_Influence", "School_Type", "Gender"]
ohe_matrix = ohe.fit_transform(df_enc[ohe_cols])

```

Доля единиц после бинаризации приведена в таблице 4.2. Доступ в интернет есть у 92,4 % наблюдений очищенной выборки, трудности в обучении – у 10,3 %. Доля Public по School_Type_bin равна 0,696.

Таблица 4.2 – Доля единиц после бинаризации

Признак	Доля единиц
Extracurricular_Activities_bin	0,595
Internet_Access_bin	0,924
Learning_Disabilities_bin	0,103
Gender_bin	0,577
School_Type_bin	0,696

4.3 Порядковое кодирование

Там, где уровни упорядочены, сохраняется порядок, а не набор независимых индикаторов. Шкала Low < Medium < High отображается в 0, 1, 2 для Parental_Involvement, Access_to_Resources, Motivation_Level, Family_Income и Teacher_Quality. Удалённость кодируется как Near = 0, Moderate = 1, Far = 2. Образование родителей кодируется как High School = 0, College = 1, Postgraduate = 2.

4.4 Унитарное кодирование

Признаки без естественного порядка – Peer_Influence, School_Type и Gender – раскладываются one-hot кодированием. Параметр drop="first" отбрасывает один уровень, чтобы индикаторы не были линейно зависимы. Опорными уровнями остаются Negative, Private и Female. В таблицу добавляются столбцы Peer_Influence_Neutral, Peer_Influence_Positive, School_Type_Public и Gender_Male.

После добавления индикаторов полная таблица имеет размер 6054×40: в ней сохранены исходные текстовые столбцы и все новые числовые представления.

4.5 Матрица для масштабирования

В матрицу X, которая далее масштабируется, текстовые столбцы не входят. В неё включаются семь исходных числовых признаков, четыре новых, пять бинарных, семь порядковых и четыре индикатора one-hot. Получается 27 столбцов при 6054 строках.

Пол и тип школы представлены дважды: Gender_bin совпадает с Gender_Male, School_Type_bin совпадает с School_Type_Public. Повтор возник потому, что к одним и тем же признакам применены и бинаризация, и one-hot. Для обучения модели достаточно одного из этих представлений.

5 СТАНДАРТИЗАЦИЯ И НОРМАЛИЗАЦИЯ

Столбцы матрицы X измерены в разных шкалах: посещаемость лежит около 80, порядковые коды – в диапазоне от 0 до 2, бинарные признаки – в диапазоне от 0 до 1. Чтобы масштаб признака не определял его вес в методах, чувствительных к расстоянию, применяются два преобразования.

Стандартизация приводит столбец к нулевому среднему и единичному стандартному отклонению:

$$z = \frac{x - \mu}{\sigma}, \quad (5.1)$$

где x – исходное значение;

μ – выборочное среднее столбца;

σ – выборочное стандартное отклонение столбца.

Нормализация переводит столбец в отрезок от 0 до 1:

$$y = \frac{x - x_0}{x_1 - x_0}. \quad (5.2)$$

где x_0 – минимум столбца;

x_1 – максимум столбца.

Преобразование (5.1) выполняется `StandardScaler`, преобразование (5.2) – `MinMaxScaler`. Оба преобразования оцениваются по всей матрице X . Программа приведена ниже.

```
scaler_std = StandardScaler()
X_standardized = pd.DataFrame(
    scaler_std.fit_transform(X),
    columns=X.columns,
    index=X.index,
)

scaler_mm = MinMaxScaler()
X_normalized = pd.DataFrame(
    scaler_mm.fit_transform(X),
    columns=X.columns,
    index=X.index,
)

X_standardized.to_csv(
    "StudentPerformanceFactors/prepared_standardized.csv", index=False
)
X_normalized.to_csv(
    "StudentPerformanceFactors/prepared_normalized.csv", index=False
)
df_clean.to_csv(
    "StudentPerformanceFactors/cleaned_raw.csv", index=False
)
```

Контроль результата: после стандартизации среднее каждого из 27 столбцов равно нулю, стандартное отклонение (при делителе n) равно единице. После нормализации минимум каждого столбца равен нулю, максимум равен единице.

Форма распределений при этом не меняется, сдвигается и растягивается только шкала. Это видно на рисунке 5.1 для Hours_Studied, Attendance, Previous_Scores, Exam_Score и Study_Intensity: верхний ряд – исходные значения, средний – стандартизация, нижний – нормализация.




Рисунок 5.1 – Распределения до и после масштабирования

Три файла записаны в каталог StudentPerformanceFactors. Файл cleaned_raw.csv содержит очищенные признаки. Файл prepared_standardized.csv содержит матрицу после формулы (5.1). Файл prepared_normalized.csv содержит матрицу после формулы (5.2).

6 ВЫВОДЫ

1 Импортирован набор «Student Performance Factors»: 6607 наблюдений и 20 признаков, из них семь числовых и тринадцать категориальных. Балл экзамена сосредоточен около 67, сильнее всего он линейно связан с посещаемостью и часами учёбы.

2 Обнаружены 235 пропусков в трёх категориальных столбцах (229 строк, 3,47 %). Пропуски заполнены модой. По правилу межквартильного размаха удалены хвосты Hours_Studied, Tutoring_Sessions и Exam_Score; значение балла 101 предварительно ограничено сотней. В выборке осталось 6054 строки. После очистки пропусков нет, повторный поиск выбросов по тем же трём признакам даёт ноль. Основное сокращение выборки связано с правым хвостом числа занятий с репетитором, а узкий разброс балла экзамена заставляет правило IQR относить к выбросам и допустимые редкие оценки.

3 Построены четыре признака: интенсивность учёбы, прирост балла, баланс сна и суммарная учебная нагрузка. Категории закодированы бинаризацией, порядковыми кодами и one-hot с отбрасыванием опорного уровня. Числовая матрица для масштабирования содержит 27 столбцов; пол и тип школы входят в неё двумя совпадающими представлениями.

4 Выполнены стандартизация и нормализация всех 27 столбцов. Среднее стандартизованных столбцов равно нулю, стандартное отклонение равно единице; нормализованные столбцы лежат на отрезке от 0 до 1. Очищенная таблица и обе матрицы сохранены в CSV.